

Carga e Transformação de Dados

Modelo Analítico de Dados para E-commerce

Sumário

1	Introdução	3
2	Arquitetura do ELT	3
2.1	Camada RAW	3
2.2	Camada CORE	3
2.3	Atomicidade do pipeline completo	4
3	Contrato de Ingestão RAW	4
4	Mapeamento RAW para CORE	5
5	Regras de Qualidade e Saneamento	6
6	Implementação	7
7	Configuração e Execução	7
8	Validação e Testes	8
9	Resultado da Carga	8
10	Rastreabilidade e Limites	9
11	Conclusão	9

1 Introdução

Este documento consolida o processo de carga e transformação do projeto *Modelo Analítico de Dados para E-commerce*, desde os nove arquivos CSV do *Brazilian E-Commerce Public Dataset by Olist* até a publicação do modelo relacional no schema *core* do PostgreSQL.

A solução segue uma arquitetura ELT: os dados são inicialmente carregados na camada RAW com mínima interferência e, em seguida, transformados dentro do banco para o CORE. O objetivo é garantir reprodutibilidade, rastreabilidade, integridade e reconciliação entre fonte e destino.

Dataset Olist → RAW → CORE → ANALYTICS → Power BI / SQL

As decisões são descritas por sua finalidade técnica e semântica, sem depender de identificadores internos utilizados no gerenciamento do projeto.

2 Arquitetura do ELT

2.1 Camada RAW

A camada RAW preserva os valores recebidos da fonte. Existe uma tabela correspondente a cada CSV; as colunas de negócio mantêm os nomes originais e são armazenadas inicialmente como `text`.

Cada ocorrência recebe os metadados técnicos:

- `_id_raw`: identificador técnico da ocorrência carregada;
- `_arquivo_origem`: identificação do arquivo de origem;
- `_carregado_em`: instante em que o registro foi incorporado à RAW.

A política de recarga é substitutiva e atômica: uma nova carga aprovada substitui integralmente a anterior. Falhas durante a operação provocam *rollback*, preservando o estado previamente publicado.

2.2 Camada CORE

O CORE materializa o modelo relacional aprovado. As transformações incluem:

- conversões explícitas de tipos;

- renomeações de atributos;
- aplicação das constraints físicas;
- derivação de prefixos de CEP;
- consolidação das duplicidades integrais de geolocalização;
- reconciliação dos volumes inseridos.

A ordem de dependências adotada é:

1. `core.prefixo_cep`;
2. `core.cliente`, `core.produto` e `core.vendedor`;
3. `core.pedido` e `core.geolocalizacao`;
4. `core.item_pedido`, `core.pagamento` e `core.avaliacao`.

2.3 Atomicidade do pipeline completo

O comando completo usa uma única conexão PostgreSQL para o fluxo CSV → RAW → CORE. O controle transacional é realizado pelo `psycpg`. Se qualquer arquivo, conversão, constraint ou reconciliação falhar, RAW e CORE retornam conjuntamente ao estado anterior.

3 Contrato de Ingestão RAW

A ingestão contempla exclusivamente os nove arquivos contratados. Arquivos adicionais exigem alteração explícita do contrato e dos artefatos físicos.

Arquivo	Linhas	Destino RAW
<code>olist_customers_dataset.csv</code>	99.441	<code>olist_customers</code>
<code>olist_geolocation_dataset.csv</code>	1.000.163	<code>olist_geolocation</code>
<code>olist_order_items_dataset.csv</code>	112.650	<code>olist_order_items</code>
<code>olist_order_payments_dataset.csv</code>	103.886	<code>olist_order_payments</code>
<code>olist_order_reviews_dataset.csv</code>	99.224	<code>olist_order_reviews</code>
<code>olist_orders_dataset.csv</code>	99.441	<code>olist_orders</code>
<code>olist_products_dataset.csv</code>	32.951	<code>olist_products</code>

Arquivo	Linhas	Destino RAW
olist_sellers_dataset.csv	3.095	olist_sellers
product_category_name_translation.csv	71	product_category_name_translation
Total	1.550.922	9 tabelas

A pré-validação confirma, antes de qualquer alteração no banco:

- presença dos nove arquivos obrigatórios;
- leitura UTF-8 ou UTF-8 com BOM;
- cabeçalho exato e na ordem contratada;
- quantidade correta de campos em todas as linhas;
- sintaxe CSV válida;
- quantidade de registros;
- tamanho e hash SHA-256 de cada fonte.

Campos vazios podem ser carregados como SQL NULL. Strings não vazias semelhantes a marcadores de ausência não são reinterpretadas. Duplicidades e inconsistências de negócio permanecem preservadas na RAW.

4 Mapeamento RAW para CORE

O mapeamento preserva identificadores de 32 caracteres como texto, prefixos de CEP como cinco caracteres, valores monetários em numeric(12,2) e datas em timestamp without time zone. Valores inválidos não são corrigidos ou descartados silenciosamente.

Origem	Destino CORE	Tratamento principal
olist_customers	cliente	Identificadores, CEP, cidade e UF
olist_orders	pedido	Status e eventos temporais
olist_order_items	item_pedido	Item, produto, vendedor, preço e frete
olist_products	produto	Categoria, descritores e medidas físicas
olist_sellers	vendedor	Identificador, CEP, cidade e UF

Origem	Destino CORE	Tratamento principal
olist_order_payments	pagamento	Sequência, tipo, parcelas e valor
olist_order_reviews	avaliacao	PK composta, nota e datas
Clientes + vendedores + geolocalização	prefixo_cep	União distinta dos prefixos
olist_geolocation	geolocalizacao	Deduplicação exata e identity

Título e mensagem das avaliações e a tabela de tradução de categorias permanecem disponíveis na RAW porque não possuem destino no CORE aprovado.

5 Regras de Qualidade e Saneamento

As regras são classificadas como bloqueantes, transformações ou informativas. Violações bloqueantes impedem a publicação do CORE; transformações aprovadas alteram o dado de forma determinística e reconciliável; características válidas incomuns são preservadas.

Entre os controles aplicados estão:

- preservação de NOT NULL, PK, FK, UNIQUE e CHECK;
- validação do formato dos identificadores quando aplicável;
- prefixos de CEP com cinco dígitos e preservação de zeros à esquerda;
- validação dos domínios de UF, status de pedido e tipo de pagamento;
- conversão estrita de datas para timestamp sem fuso;
- valores monetários não negativos com precisão decimal exata;
- notas de avaliação entre 1 e 5;
- latitude e longitude dentro dos limites globais;
- integridade referencial entre as entidades carregadas.

O profiling de qualidade avaliou 113 regras sobre o snapshot e encontrou **zero violações bloqueantes**. Foram identificadas 261.831 duplicidades integrais de geolocalização, consolidadas de forma determinística, e 19.177 prefixos de CEP distintos derivados.

6 Implementação

Artefato	Responsabilidade
etl/raw_loader.py	Pré-validação, COPY, recarga substitutiva e reconciliação RAW
etl/sql/load_core.sql	Transformações SQL na ordem de dependências
etl/core_loader.py	Execução e reconciliação do CORE
etl/pipeline.py	Orquestração atômica CSV → RAW → CORE
config/raw_load.toml	Contrato operacional das fontes RAW
config/core_load.toml	Configuração da transformação CORE
tests/	Testes automatizados dos loaders e do pipeline

7 Configuração e Execução

Credenciais não são versionadas. No ambiente local, a conexão pode ser armazenada em `.env`, ignorado pelo Git, enquanto um arquivo de exemplo sem segredo documenta a variável necessária.

```
DATABASE_URL=postgresql://usuario:senha@localhost:5432/ecommerce
```

Com o banco físico previamente criado, a execução operacional do pipeline completo é:

```
uv run python -m etl.pipeline
```

A pré-validação isolada continua disponível por:

```
uv run python -m etl.pipeline --validate-only
```

Cada execução completa gera um log JSON local em:

```
outputs/data-loading/logs/full_load_<run_id>.json
```

O registro contém perfis e hashes das fontes, reconciliações RAW e CORE, hash do SQL de transformação, horários, modo, status e erro quando houver. A URL de conexão não é registrada.

8 Validação e Testes

A implementação foi validada em PostgreSQL 18.6 temporário e isolado, com duas execuções completas consecutivas sem acumulação. Um erro deliberado ao final da transformação confirmou rollback conjunto de RAW e CORE.

A execução na base persistente de teste também foi concluída com status **APPROVED**, após recriação do schema físico e dos índices.

A suíte automatizada atual contém 20 testes aprovados. Cinco deles exercitam diretamente o pipeline completo:

- validação sem conexão;
- ausência de DATABASE_URL;
- compartilhamento da mesma conexão entre RAW e CORE;
- propagação de falha no CORE;
- presença das reconciliações RAW e CORE no resultado.

A suíte completa é executada com:

```
uv run python -m unittest discover -s tests -v
```

9 Resultado da Carga

Os volumes reconciliados no CORE para o snapshot validado são:

Tabela CORE	Registros reconciliados
prefixo_cep	19.177
cliente	99.441
produto	32.951
vendedor	3.095
pedido	99.441
item_pedido	112.650
pagamento	103.886
avaliacao	99.224
geolocalizacao	738.332

Tabela CORE	Registros reconciliados
Total físico	1.308.197

O total CORE não deve ser comparado diretamente ao total RAW como se ambas as camadas possuíssem a mesma granularidade. A diferença decorre da entidade derivada de prefixos, da consolidação de geolocalização, da tabela de tradução sem destino e das granularidades próprias das entidades.

10 Rastreabilidade e Limites

A RAW mantém o valor original e os metadados técnicos necessários para localizar a ocorrência carregada. Falhas do PostgreSQL e divergências de reconciliação interrompem a transação e são registradas no log operacional.

O contrato de qualidade prevê que violações bloqueantes sejam associadas, quando aplicável, à carga, tabela, arquivo, `_id_raw`, coluna, valor original, regra e motivo. A implementação atual garante bloqueio transacional e registro da falha, mas o detalhamento estruturado por regra permanece um ponto de evolução para cenários em que o snapshot apresente violações bloqueantes.

Agendamento, observabilidade de produção e objetos do schema `analytics` não fazem parte desta entrega.

11 Conclusão

O processo de carga e transformação está implementado de forma reproduzível e transacional. Os nove CSVs são pré-validados, carregados e reconciliados na RAW; as transformações materializam as nove tabelas do CORE respeitando dependências e constraints; e o pipeline completo publica as duas camadas somente após aprovação das verificações.

Com a execução integrada aprovada e a cobertura automatizada do pipeline, o banco fica preparado para a validação final de reconciliação e, posteriormente, para a construção das estruturas analíticas destinadas ao consumo.