

Modelagem Física

Modelo Analítico de Dados para E-commerce

Sumário

1	Introdução	3
2	Sistema Gerenciador de Banco de Dados	3
3	Arquitetura Física em Camadas	3
4	Evidências para os Tipos Físicos	5
5	Dicionário Físico do CORE	5
6	Estratégia Inicial de Índices	7
7	Scripts e Operação	7
8	Validação da Arquitetura	8
9	Conclusão	8
10	Referências	8

1 Introdução

Este documento consolida a modelagem física do projeto *Modelo Analítico de Dados para E-commerce*. O modelo lógico aprovado é materializado no PostgreSQL por meio de tipos concretos, nulabilidade, chaves, restrições, índices e scripts SQL reproduzíveis.

A solução segue uma arquitetura ELT em três camadas:

Dataset Olist → RAW → CORE → ANALYTICS → Power BI / SQL

A modelagem preserva a semântica e a granularidade aprovadas. Decisões de carga, transformação e consumo analítico são descritas por sua finalidade, sem depender da numeração operacional utilizada no gerenciamento do projeto.

2 Sistema Gerenciador de Banco de Dados

O SGBD adotado é o **PostgreSQL 18**, sempre em sua revisão secundária mais recente disponível. A escolha considera:

- suporte nativo a chaves, integridade referencial, transações e restrições de domínio;
- tipos adequados para valores monetários exatos, coordenadas e dados temporais;
- recursos SQL para junções, agregações, funções de janela e CTEs;
- ferramentas de linha de comando para automação e validação;
- integração com Python, DBeaver e ferramentas de BI;
- manutenção ativa, documentação oficial e licença livre.

O DBeaver é utilizado como cliente gráfico para conexão, execução de scripts e inspeção de objetos. Ele não substitui o servidor PostgreSQL nem os testes reproduzíveis. Credenciais e configurações locais não são versionadas.

3 Arquitetura Física em Camadas

3.1 RAW

O schema `raw` recebe uma representação fiel dos nove arquivos CSV. Há uma tabela por arquivo, os nomes originais das colunas são preservados e os valores de origem são armazenados como `text`. Dessa forma, uma falha de conversão não impede a ingestão nem elimina a evidência original.

Cada tabela acrescenta somente:

- `_id_raw`: identidade técnica da ocorrência;
- `_arquivo_origem`: nome do arquivo recebido;
- `_carregado_em`: instante da ingestão.

Os campos da fonte permanecem anuláveis e não recebem regras de negócio. A chave técnica não afirma unicidade sobre o conteúdo original.

3.2 CORE

O schema `core` materializa as nove tabelas relacionais aprovadas. Renomeações, conversões, deduplicação e validações ocorrem no fluxo RAW–CORE. O CORE é a fonte estruturada e íntegra para consultas e para a produção das estruturas analíticas.

3.3 ANALYTICS

O schema `analytics` é inicialmente criado sem objetos. Views, marts e métricas serão derivados do CORE quando suas granularidades, regras e finalidades de consumo estiverem definidas. Power BI e consumidores SQL deverão utilizar preferencialmente essa camada.

3.4 Mapeamento dos Arquivos para a RAW

Arquivo	Tabela RAW
<code>olist_customers_dataset.csv</code>	<code>raw.olist_customers</code>
<code>olist_geolocation_dataset.csv</code>	<code>raw.olist_geolocation</code>
<code>olist_order_items_dataset.csv</code>	<code>raw.olist_order_items</code>
<code>olist_order_payments_dataset.csv</code>	<code>raw.olist_order_payments</code>
<code>olist_order_reviews_dataset.csv</code>	<code>raw.olist_order_reviews</code>
<code>olist_orders_dataset.csv</code>	<code>raw.olist_orders</code>
<code>olist_products_dataset.csv</code>	<code>raw.olist_products</code>
<code>olist_sellers_dataset.csv</code>	<code>raw.olist_sellers</code>

Arquivo	Tabela RAW
product_category_name_translation.csv	raw.product_category_name_translation

4 Evidências para os Tipos Físicos

Os CSVs foram perfilados como texto para evitar inferência indevida. Foram avaliados nulidade, comprimento, domínio, mínimo, máximo, escala decimal, formato temporal, unicidade e integridade referencial.

Domínio	Evidência	Decisão
Identificadores	32 caracteres hexadecimais	varchar(32); não converter para UUID
Prefixo de CEP	exatamente cinco dígitos	char(5) com validação
UF	dois caracteres; conjunto das UFs brasileiras	char(2) com domínio
Cidades	maior ocorrência com 40 caracteres	varchar(50)
Categoria	maior ocorrência com 46 caracteres	varchar(50)
Valores monetários	duas casas; máximo 13.664,08	numeric(12,2)
Datas e horas	formato válido, sem deslocamento UTC	timestamp without time zone
Coordenadas	precisão variável e pontos fora do Brasil	double precision; limites globais

5 Dicionário Físico do CORE

As colunas sem indicação de nulabilidade são obrigatórias. Nenhum valor de negócio recebe padrão implícito. Somente `geolocalizacao.id_geolocalizacao`, inexistente na fonte, é gerado como `bigint generated always as identity`.

Tabela	Coluna	Tipo	Integridade e observações
cliente	id_cliente	varchar(32)	PK; hexadecimal
cliente	id_cliente_unico	varchar(32)	hexadecimal
cliente	prefixo_cep	char(5)	FK; cinco dígitos

Modelagem Física

Tabela	Coluna	Tipo	Integridade e observações
cliente	cidade / estado	varchar(50) / char(2)	texto não vazio; UF válida
pedido	id_pedido	varchar(32)	PK; hexadecimal
pedido	id_cliente	varchar(32)	FK e UNIQUE
pedido	status_pedido	varchar(20)	domínio dos estados observados
pedido	datas do ciclo	timestamp without time zone	aprovação, envio e entrega podem ser nulos
item_pedido	id_pedido, id_item	varchar(32), smallint	PK composta; item positivo
item_pedido	id_produto, id_vendedor	varchar(32)	FKs
item_pedido	preço e frete	numeric(12,2)	valores não negativos
produto	id_produto	varchar(32)	PK; hexadecimal
produto	nome_categoria	varchar(50)	anulável
produto	métricas e dimensões	smallint / integer	anuláveis e não negativas
vendedor	id_vendedor	varchar(32)	PK; hexadecimal
vendedor	prefixo, cidade, estado	char(5), varchar(50), char(2)	FK e domínios geográficos
pagamento	id_pedido, sequencial	varchar(32), smallint	PK composta; FK; sequência positiva
pagamento	tipo / parcelas / valor	varchar(20), smallint, numeric(12,2)	domínios e valores não negativos
avaliacao	id_avaliacao, id_pedido	varchar(32)	PK composta; FK
avaliacao	nota / datas	smallint, timestamp	nota entre 1 e 5
prefixo_cep	prefixo_cep	char(5)	PK; cinco dígitos
geolocalizacao	id_geolocalizacao	bigint identity	PK gerada
geolocalizacao	prefixo_cep	char(5)	FK
geolocalizacao	latitude / longitude	double precision	limites globais
geolocalizacao	cidade / estado	varchar(50) / char(2)	texto não vazio; UF válida

As exclusões referenciadas usam `ON DELETE RESTRICT`; atualizações de identificadores usam `ON UPDATE NO ACTION`. Não são impostas comparações universais entre datas. Nulos descritivos e físicos observados em produtos são preservados, sem preenchimento artificial.

6 Estratégia Inicial de Índices

O PostgreSQL cria índices B-tree para PKs e restrições `UNIQUE`, mas não indexa automaticamente as colunas que referenciam FKs. Uma FK é considerada coberta quando suas colunas formam o prefixo à esquerda de um índice existente.

Foram aprovados seis índices adicionais:

- `idx_cliente_prefixo_cep`;
- `idx_vendedor_prefixo_cep`;
- `idx_item_pedido_id_produto`;
- `idx_item_pedido_id_vendedor`;
- `idx_avaliacao_id_pedido`;
- `idx_geolocalizacao_prefixo_cep`.

Não há índices adicionais na RAW antes da implementação das transformações, pois eles aumentariam o custo de ingestão sem padrão de acesso comprovado. Também não há índices em ANALYTICS enquanto o schema estiver vazio. Depois da carga, estatísticas, consultas reais e planos de execução deverão orientar qualquer revisão.

7 Scripts e Operação

Os artefatos técnicos são:

- `create_schema.sql`: cria os três schemas e as tabelas;
- `create_indexes.sql`: cria os seis índices adicionais;
- `validate_schema.sql`: valida catálogo e comportamento;
- `drop_indexes.sql`: remove os índices adicionais;
- `drop_schema.sql`: remove tabelas e schemas em ordem segura.

No DBeaver, a criação é realizada executando `create_schema.sql`, `create_indexes.sql` e `validate_schema.sql`, nessa ordem. A criação falha intencionalmente quando os schemas já existem, protegendo objetos contra redefinição silenciosa. A remoção deve ser executada somente em ambiente descartável ou mediante autorização explícita.

8 Validação da Arquitetura

A arquitetura foi executada em uma instância limpa do PostgreSQL 18.3. O resultado consolidado foi:

Verificação	Esperado	Obtido
Schemas físicos	3	3
Tabelas RAW / CORE / ANALYTICS	9 / 9 / 0	9 / 9 / 0
Colunas RAW / CORE	79 / 50	79 / 50
Colunas identity	10	10
Chaves primárias / estrangeiras / UNIQUE	18 / 9 / 1	18 / 9 / 1
Índices RAW / CORE / adicionais CORE	9 / 16 / 6	9 / 16 / 6

A RAW aceitou deliberadamente valores fora dos domínios de negócio. O CORE rejeitou CEP inválido, chave duplicada e referência órfã. Os registros de teste foram revertidos. Uma segunda criação foi rejeitada sem danificar as tabelas existentes, e a remoção pôde ser repetida sem erro.

9 Conclusão

A modelagem física está consistente com os modelos conceitual e lógico e pronta para receber o processo ELT. A etapa seguinte deverá extrair os CSVs, carregá-los com rastreabilidade na RAW, transformar e validar os dados no CORE e reconciliar volumes e rejeições. Em seguida, estruturas analíticas derivadas do CORE poderão ser disponibilizadas para Power BI e consultas SQL.

10 Referências

- PostgreSQL. *Versioning Policy*. Disponível em: <https://www.postgresql.org/support/versioning/>.

- PostgreSQL. *PostgreSQL 18 Documentation*. Disponível em: <https://www.postgresql.org/docs/18/>.
- DBeaver. *PostgreSQL driver documentation*. Disponível em: <https://dbeaver.com/docs/dbeaver/Database-driver-PostgreSQL/>.